

Informe Técnico

Entrega 1: Entrenamiento

Predicción de Abandono de Clientes (Churn)

AndesLink Servicios Digitales S.A.

Materia: Laboratorio de Minería de Datos

Profesor: Ing. Diego Mosquera

Alumnos:

Facundo Zubeldia

Agustín Emanuel Meza

Gonzalo Martín González Nastovich

1. Problema de Negocio

AndesLink Servicios Digitales S.A. comercializa planes de suscripción mensual para servicios digitales orientados a consumidores finales. Durante los últimos trimestres, la empresa detectó una tasa creciente de cancelación voluntaria de clientes (churn), lo que impacta negativamente en los ingresos recurrentes, el costo de adquisición de nuevos usuarios y la estabilidad del flujo de caja.

El objetivo analítico es entrenar un modelo de clasificación binaria capaz de estimar la probabilidad de que un cliente abandone el servicio, a partir de variables de comportamiento, antigüedad, facturación y relación con el servicio.

Variable objetivo: churn — valor 1 si el cliente abandonó el servicio, 0 si continúa activo.

2. Dataset

Procedencia: Dataset sintético diseñado para simular el comportamiento real de clientes de una empresa de suscripciones digitales.

Tamaño: 5.000 registros · 16 columnas (15 features + 1 variable objetivo).

Versionado: El dataset está versionado con DVC. El archivo CSV no se commitea al repositorio; se almacena el archivo churn_sintetico.csv.dvc con el hash del dato. El archivo real se descarga con dvc pull.

Variables principales:

Variable	Tipo	Descripción
tenure_months	Numérica	Meses de antigüedad del cliente
monthly_charge	Numérica	Cargo mensual
total_charges	Numérica	Cargo total acumulado (derivada)
support_tickets	Numérica	Tickets de soporte generados
late_payments	Numérica	Pagos tardíos registrados
avg_monthly_usage_gb	Numérica	Uso promedio mensual en GB
contract_type	Categoría	Tipo de contrato: mensual / anual / bianual
payment_method	Categoría	Método de pago
internet_service	Categoría	Tipo de servicio: fibra / cable / móvil / ninguno
region	Categoría	Region geográfica del cliente
has_streaming	Binaria	Tiene servicio de streaming (0/1)
has_security_pack	Binaria	Tiene paquete de seguridad (0/1)
num_products	Numérica	Cantidad de productos contratados
customer_age	Numérica	Edad del cliente
is_promo	Binaria	Ingreso con promoción (0/1)

Limitaciones del dataset:

- Dataset sintético: los patrones pueden no reflejar el comportamiento real de clientes.
- total_charges es una variable derivada (tenure x monthly_charge), introduce colinealidad ($r=0.87$ con tenure_months).
- Las correlaciones con churn son bajas (max $r=-0.17$), sugiriendo dependencias no lineales.

3. Análisis Exploratorio (EDA)

3.1 Distribución de la variable objetivo

El dataset presenta un desbalance moderado: 66% de clientes que se quedan (clase 0) vs. 34% que se van (clase 1). Este desbalance determina que accuracy no sea la métrica correcta: un modelo que prediga siempre clase 0 tendría 66% de accuracy sin detectar ningún cliente en riesgo.




Figura 1: Distribución de la variable churn en el dataset.

3.2 Variables numéricas vs. churn

Los boxplots muestran diferencias clave: tenure_months (Med 0: 39 vs Med 1: 29) y support_tickets (Med 0: 1 vs Med 1: 2) son las variables con mayor separación entre grupos, indicando que clientes nuevos con muchos tickets tienen mayor propensión al churn.




Figura 2: Distribución de variables numéricas — clientes que se quedan vs. que se van.

3.3 Matriz de correlación

Se confirma la colinealidad entre `total_charges`, `tenure_months` ($r=0.87$) y `monthly_charge` ($r=0.41$). La variable con mayor correlación con `churn` es `tenure_months` ($r=-0.17$): mayor antigüedad implica menor riesgo de abandono.




Figura 3: Matriz de correlación entre variables numéricas.

3.4 Variables categóricas vs. churn

El análisis de tasa de churn por categoría revela hallazgos de negocio relevantes:




Figura 4: Tasa de churn por variable categórica.

- contract_type: contratos mensuales tienen 47.5% de churn vs. 11.6% en bianuales.
- internet_service: servicio móvil tiene 50.9% de churn; fibra solo 26.8%.
- payment_method: efectivo tiene mayor churn (40.5%), asociado a menor automatización.
- region: sin diferencias significativas (33-34%); el churn no tiene componente geográfico.

4. Preparación de Datos

Limpieza:

- Eliminación de customer_id (identificador único, no predictivo).
- Verificación y eliminación de duplicados.
- Sin valores nulos detectados en el dataset.

Separación train/test:

División 80/20 con random_state=42. El 20% (1.000 registros) se reservó para evaluación final sin participar en el entrenamiento.

Pipeline de preprocesamiento:

Se implementó un Pipeline de scikit-learn que aplica transformaciones de forma consistente:

- Variables numéricas: StandardScaler (media 0, desvió 1). Necesario para convergencia de Logistic Regression.
- Variables categóricas: OneHotEncoder con handle_unknown='ignore'. Robusto ante categorías nuevas en inferencia.

El pipeline completo (preprocesador + clasificador) se serializa en un único artefacto .pkl, garantizando que la inferencia aplique exactamente las mismas transformaciones.

5. Entrenamiento y Evaluación

5.1 Elección de métricas

Con 34% de churn, la accuracy no es la métrica correcta. La métrica principal es el F1-score de la clase 1 (churn), que balancea precision y recall.

El Recall es especialmente relevante: mide cuantos de los clientes que realmente se van son detectados. Un recall bajo implica campanas de retención ineficaces.

El ROC_AUC se usa para comparar la capacidad discriminativa de los modelos independientemente del umbral.

5.2 Comparación de modelos

Se compararon tres algoritmos, todos con class_weight='balanced' para penalizar errores sobre la clase minoritaria:

Modelo	Accuracy	F1 (churn)	Recall (churn)	ROC-AUC
Logistic Regression	0.703	0.609	0.704	0.768
Decision Tree	0.671	0.582	0.698	0.729
Random Forest	0.712	0.444	0.351	0.732

Tabla 1: Comparación de modelos. Logistic Regression = modelo seleccionado.

5.3 Modelo seleccionado: Logistic Regression

Seleccionada por tener el mayor F1-score (0.609), Recall (0.704) y ROC-AUC (0.768).


Random Forest, a pesar de tener el mayor accuracy (0.712), tuvo el peor F1 y Recall (0.444 y 0.351).

Esto confirma porque accuracy no es la métrica correcta: Random Forest aprendió a predecir bien la clase mayoritaria, pero fallo en detectar clientes en riesgo de fuga.

6. Tracking de Experimentos

Todos los test fueron registrados con Mlflow bajo el experimento 'AndesLink_Churn_Prediction'.

Se loguearon F1, Recall y ROC-AUC por cada modelo. La base de datos se almacena en notebooks/mlflow.db



☐	Run Name	Created	Dataset	Duration	Source	Models
☐	Random_Forest	2 hours ago	-	432ms	01_eda...	-
☐	Decision_Tree	2 hours ago	-	34ms	01_eda...	-
☐	Logistic_Regression	2 hours ago	-	35ms	01_eda...	-
☐	charming-shrew-580	2 hours ago	-	0.9s	01_eda...	-

Figura 5: UI de MLflow con los 3 runs del experimento.

Estrategia de reproducibilidad:

- Git: versionado del código fuente y archivos de configuración.
- DVC: versionado del dataset. El CSV no se commitea al repo (churn_sintetico.csv.dvc).
- MLflow: tracking de experimentos, hiperparámetros y métricas.
- environment.yml + requirements.txt: entorno reproducible con versiones fijas.

7. Conclusiones y Limitaciones

Se desarrolló un pipeline MLOps completo para la Entrega 1, desde la exploración del dataset hasta el modelo serializado listo para inferencia.

La Regresión Logística con `class_weight='balanced'` es el modelo final, con F1=0.609 y Recall=0.704 en la clase churn.

Limitaciones:

- Dataset sintético: puede no reflejar comportamiento real de clientes.
- Sin optimización de hiperparámetros (GridSearch/RandomSearch). Hay margen de mejora.
- total_charges introduce colinealidad; podría evaluarse su eliminación.
- Recall del 70.4%: el modelo aun no detecta el 30% de los clientes en riesgo.

Próximos pasos (Entrega 2):

- Exponer el modelo como API REST con FastAPI.
- Construir dashboard con Streamlit para usuarios no técnicos.
- ContenedORIZAR la solución con Docker y Docker Compose.